

Counterfactual Conversation Emulation for Off-Policy Evaluation of Medical Agents

提出 **counterfactual conversation emulation**: 用历史医患对话数据 retrospectively 估计 medical AI agent 部署后的 causal effect, 作为昂贵缓慢的 prospective clinical trial 的替代方案。

现状的 **gap**:

- Prospective medical agent trial 周期数月、成本上百万, 但 agent 每几个月更新一次——等结果出来 agent 已过时。
- Static benchmark (MedQA、USMLE 类) 只测 isolated capability, 不测部署后真实交互中的 causal effect。

以前为什么没人做:

- Target trial emulation (Hernán-Robins) 假设 treatment 是固定物理干预; agent 是 policy。
- Off-policy evaluation 假设 action 是 discrete / low-dimensional; agent 的 action 是 free-form natural language。
- 两个领域没交叉过, medical agent 评估正好卡在中间。

核心技术挑战: Conversation 作为 Action

这是整个项目的方法论核心。理解清楚这一点, paper 的 novelty 就立住了。

传统 OPE 假设 vs 我们的 setting

- 传统 OPE: action 是 discrete 或低维 continuous, $\pi(a|x)$ 解析可算, importance ratio $w = \pi_{\text{target}}/\pi_b$ 可直接计算。
- 我们的 setting: action 是 natural language conversation。Sequence-level 的概率指数级小, clinician 的 π_b 完全未知 (人不是 stochastic policy)。
- 结论: 传统 importance sampling 根本无法用。需要新方法。

解决思路: 在 embedding space 做 OPE

核心 trick (基于 Saito & Joachims 2022 MIPS): 把 conversation a embed 到低维 vector $\phi(a)$, importance weight 不在 action space 算, 而在 embedding space 算:

$$w(x, a) = p(\phi(a) | x, \pi_{\text{agent}}) / p(\phi(a) | x, \pi_b)$$

用 classifier-based density ratio estimation: 训一个 classifier 区分 agent 和 clinician 的 conversation embedding, 从 logit 推 ratio。

两个关键假设 (必须在 paper 里讨论清楚)

1. **Common embedding support**: embedding 空间的 positivity。比 action 空间的 positivity 弱, 更容易满足。

2. **No direct effect**: action 对 reward 的影响完全通过 embedding mediate。现实中很难完全成立——同样的诊断结论, 措辞不同效果就不一样。所以需要 OffCEM-style 的修正 (见 Phase 4)。

阶段 1: 问题形式化 (第 1 周)

目标。把 idea 转成精确的数学问题。

核心 estimand

$$V(\pi_{\text{agent}}) = E_x [E_{\{a \sim \pi_{\text{agent}}(\cdot|x)\}} [Y(x, a)]]$$

必须明确的关键决策

3. **Action** 粒度: 推荐用 final output (diagnosis + management plan), outcome 最容易 ground。
4. **Outcome** 定义: LLM-as-judge 的 rubric 连续评分 (0–1), 不用 binary accuracy。
5. **Target population**: clinician 写过 note 的 encounter——positivity 的自然 support。

交付物

- 一页 problem statement: estimand、假设、notation table。

阶段 2: 数据集构建 (第 2–3 周)

目标。从公开医疗对话数据集构造 $D = \{(x, a^{\text{clinician}}, y)\}$ 。

数据源 (按推荐度)

- **ACI-Bench**: 207 条完整 encounter + clinical note。规模小但干净, prototype 用。
- **MTS-Dialog**: 约 1700 条 dialogue–note snippet 对。Scale up 用。
- **MedDialog-EN**: 0.26M 对话。规模大但杂。

处理步骤

6. 从对话抽取 x = patient presentation (决策前可得信息)。
7. a = clinician 最终输出 (assessment + plan, 从 note 抽)。
8. y = rubric LLM 对 (x, a) 的评分。

关键技术要求

x 不能含有 **clinician** 决策后才有的信息 (比如已知诊断)。否则 emulation 整个崩掉。这对应 TTE 里的 time zero。

阶段 3: Ground Truth 构造(第 4–5 周)—— 最关键

目标。在同一 x 池子上跑真实 agent vs clinician 比较, 得到 $V(\pi_{\text{agent}})$ 的 true value。这是后续 emulation 要 recover 的目标。

如果 **ground truth** 不可靠, 后面所有结果都没意义。

步骤

9. 固定 agent π_{agent} (GPT-4 + medical system prompt)。
10. 对每个 x_i , 让 agent 生成 a_i^{agent} 。
11. 用同一个 rubric LLM 评分得 y_i^{agent} 。
12. $V^{\text{true}}(\pi_{\text{agent}}) = \text{mean}(y_i^{\text{agent}})$; $V^{\text{true}}(\pi_b) = \text{mean}(\text{原始 } y_i)$ 。
13. True effect = 两者之差, bootstrap 算 CI。

Fallback: rubric LLM 不可靠

- 手工 annotate 100 个 case 校准。Spearman < 0.7 就换 rubric 或换 task (用有 gold label 的 diagnosis accuracy)。

阶段 4: Estimator 实现(第 6–8 周)

目标。实现 3 个 estimator, 各自对应到一篇 **published** 方法, 实现风险低。

Estimator 1: Direct Method (DM) + KL-control

- 基于: Jaques et al. 2019 (KL-control for dialog OPE)。
- 训 outcome model $\hat{f}(x, a) \approx E[Y|x, a]$, 用 $(x, a^{\text{clinician}}, y)$ 作为训练数据。
- KL penalty 防止 $\hat{f}$ 在 agent action 上 extrapolation 失控。
- $\hat{V}_{\text{DM}} = \text{mean}_i \hat{f}(x_i, a_i^{\text{agent}})$ 。
- 主要风险: extrapolation bias。

Estimator 2: Marginalized IPS (MIPS)

- 基于: Saito & Joachims 2022 (<https://arxiv.org/abs/2202.06317>)。直接 fork 他们的 Open Bandit Pipeline。
- Action embedding: sentence-BERT 或 OpenAI embedding (先用现成的, 后面再 ablation)。
- Marginal density ratio: 用 binary classifier 区分 agent 和 clinician 的 conversation embedding。

- $\hat{V}_{MIPS} = \text{mean}_i w(x_i, \phi(a_i^{\text{clinician}})) \cdot y_i$ 。
- 主要风险: No Direct Effect 假设可能违反——见 Estimator 3。

Estimator 3: OffCEM-style Doubly Robust

- 基于: Saito et al. 2023 (OffCEM)。
- 把 reward 分解成 cluster effect(embedding mediated) + residual effect(embedding 没 capture 的部分)。
- DM 估 cluster effect(reliable), MIPS 估 residual(小、低 variance)。

$$\hat{V}_{\text{OffCEM}} = \text{mean}_i [\hat{f}_{\text{cluster}}(x_i, \phi(a_i^{\text{agent}})) + w(x_i, \phi(a_i^{\text{clinician}})) \cdot (y_i - \hat{f}_{\text{cluster}}(x_i, \phi(a_i^{\text{clinician}})))]$$

- 预期: OffCEM > MIPS > DM, 因为 OffCEM 同时处理 extrapolation 和 No Direct Effect 违反。

交付物

- 3 个 estimator 实现 + synthetic toy problem 上的 unit test(已知 ground truth, 验证 recover)。

阶段 5: 主实验(第 9–10 周)

目标。把三个 estimator 跑在真实数据上, 和阶段 3 的 ground truth 对比。

Headline 表

Estimator	Bias	RMSE	CI Coverage	方向一致率
DM (Jaques 2019)	?	?	?	?
MIPS (Saito 2022)	?	?	?	?
OffCEM (Saito 2023)	?	?	?	?

Bootstrap B = 100 算 CI。

预期结果

- OffCEM bias 最小, 方向一致率 > 90%。
- Relative bias < 20%。

阶段 6: Failure-Mode 分析(第 11 周)

Ablation 维度

- 14. **Embedding** 选择: sentence-BERT vs OpenAI vs learned embedding (Cieff et al. 2024)。
- 15. **Agent** 强度: weak (GPT-3.5) vs strong (GPT-4), emulation 在哪个上更准?
- 16. **Positivity** 诊断: weight 分布的 tail, identify failure subpopulation。
- 17. **Conversation** 长度: 分组看 estimator 性能。
- 18. **Rubric** 敏感性: 换 judge LLM。

阶段 7: 写作 (第 12 周)

Paper Pitch

我们把 MIPS (Saito-Joachims 2022) 和 OffCEM (Saito 2023) 从 recommender system 迁移到 conversational medical agent OPE, 其中 (i) action 是 free-form natural language 而非 discrete catalog item; (ii) behavior policy 是 human clinician (unknown), 不是已知 logging policy; (iii) reward 是 LLM-judged outcome 而非 click。Characterize No Direct Effect 假设何时被违反, 以及如何用 OffCEM-style decomposition 修复。

结构

- 19. Intro: agent trial bottleneck + 我们的 insight。
- 20. Problem formulation (阶段 1) + 核心技术挑战 (conversation as action)。
- 21. Method: 3 个 estimator (阶段 4)。
- 22. Benchmark construction (阶段 2 + 3)。
- 23. Experiments (阶段 5 + 6)。
- 24. Related work: MIPS / OffCEM / dialog OPE / TTE / medical agent eval。
- 25. Limitations + future work。

关键风险和 Fallback

风险 1: rubric LLM 不可靠

Fallback: 手工校准集, 或换有 gold label 的 task。

风险 2: positivity violation 严重

Fallback: 限制 target population; 只报 DM 和 OffCEM。

风险 3: 所有 estimator 都 recover 不了 ground truth

Fallback: 重新定位成 "conversation 作为 action 的 OPE 比预期难" 的 cautionary paper, 详细 characterize failure mode。这种 paper 在 ICLR / NeurIPS 也能发。

成功判定标准

- 第 5 周末: ground truth 构造完成, true effect 统计显著。
- 第 10 周末: 至少 OffCEM 能 recover true effect 的 direction。

两个都满足, paper 可写。都不满足, 转 cautionary paper。

精选 Reading List

第一梯队(必读, 技术 backbone)

- **Saito & Joachims (2022).** *Off-Policy Evaluation for Large Action Spaces via Embeddings (MIPS)*. ICML. → <https://arxiv.org/abs/2202.06317>
- 代码: <https://github.com/usaito/icml2022-mips>
- **Saito et al. (2023).** *Off-Policy Evaluation for Large Action Spaces via Conjunct Effect Modeling (OffCEM)*. ICML. → <https://proceedings.mlr.press/v202/saito23b/saito23b.pdf>
- **Hernán & Robins (2016).** *Using Big Data to Emulate a Target Trial*. Am J Epidemiol. → <https://academic.oup.com/aje/article/183/8/758/1739860>
- **Dudík, Langford & Li (2011).** *Doubly Robust Policy Evaluation and Learning*. ICML. → <https://arxiv.org/abs/1103.4601>

第二梯队(强烈建议)

- **Cieľ et al. (2024).** *Learning Action Embeddings for Off-Policy Evaluation*. → <https://kinit.sk/wp-content/uploads/2024/03/learning-action-embeddings-for-off-policy-evaluation.pdf>
- **Jiang et al. (2021).** *Towards Automatic Evaluation of Dialog Systems: A Model-Free Off-Policy Evaluation Approach*. EMNLP. → <https://www.semanticscholar.org/paper/56586eb758d7fabdbbd5ee4c5ed7e30c6d457d30>
- **Jaques et al. (2019).** *Way Off-Policy Batch Deep Reinforcement Learning of Implicit Human Preferences in Dialog*. → <https://arxiv.org/abs/1907.00456>
- **Tu et al. (2024).** *Towards Conversational Diagnostic AI (AMIE)*. Nature. → <https://arxiv.org/abs/2401.05654>

第三梯队(参考)

- **Peng et al. (2024).** *Context-Action Embedding Learning for OPE (CAEL-MIPS)*. → <https://arxiv.org/abs/2509.00648>
- **Hernán, Wang & Leaf (2022).** *Target Trial Emulation: A Framework*. JAMA. → <https://pmc.ncbi.nlm.nih.gov/articles/PMC10400102/>
- **Schmidgall et al. (2024).** *AgentClinic: a Multimodal Agent Benchmark*. → <https://arxiv.org/abs/2405.07960>

数据集

- **ACI-Bench (2023).** 207 完整 *encounter + note*。 → https://github.com/microsoft/clinical_visit_note_summarization_corpus
- **MTS-Dialog (EACL 2023).** ~1700 *dialogue–note snippet* 对。 → <https://github.com/abachaa/MTS-Dialog>
- **MedDialog (EMNLP 2020).** 0.26M 英文 + 3.4M 中文医患对话。 → <https://github.com/UCSD-AI4H/Medical-Dialogue-System>